

# Multilinguale Spracherkennung mit tiefen neuronalen Netzen

1<sup>st</sup> Björn Beha  
Hochschule Furtwangen University  
Unterkirnach, Germany  
b.beha@hs-furtwangen.de

2<sup>nd</sup> Phillip Ginter  
Hochschule Furtwangen University  
Schramberg, Germany  
phillip.ginter@hs-furtwangen.de

3<sup>rd</sup> Suhay Sevinc  
Hochschule Furtwangen University  
Donaueschingen, Germany  
suhay.sevinc@hs-furtwangen.de

**Zusammenfassung**—Dieser Artikel beschäftigt sich mit dem Ansatz des tiefen maschinellen Lernens im Bereich der multilingualen Spracherkennung. Die Arbeit setzt sich mit der Forschungsfrage auseinander, welches Verfahren heute genutzt wird, um aktuelle Spracherkennungssysteme zu realisieren. Aus Untersuchungen geht bereits hervor, dass die hohe Genauigkeit der heutigen Spracherkennung über Long Short Term Memory-Netzwerken erreicht wird, die über eine Speicherstruktur verfügen, um sich an vorherige Zustände zu erinnern. Der Artikel konzentriert sich auf diese Form neuronaler Netze und zeigt, warum diese ideal für Sequenzen von Tönen geeignet sind. In diesem Kontext wird untersucht, wie die Erkennung mehrerer Sprachen funktioniert, auch wenn nur geringe Mengen an Trainingsdaten verfügbar sind. Vor allem diese Knappheit von Ressourcen stellt eine Herausforderung dar, da ohne eine gewisse Menge markierter Daten keine Muster und Gesetzmäßigkeiten der Sprache erkannt und beurteilt werden können. Die Abhandlung zeigt, dass dies über das gemeinsame Nutzen einzelner Töne gelöst wird und wie sich ein solches System trainieren lässt. Weiterhin bestehende Herausforderungen werden diskutiert und es wird geklärt, welche Ansätze in Zukunft verfolgt werden, um eine natürliche Interaktion zwischen Mensch und Maschine zu ermöglichen.

**Index Terms**—Tiefes Lernen, tiefe neuronale Netze, Spracherkennung, Recurrent Neural Networks, Long Short Term Memory, LSTM

## I. EINLEITUNG

SYSTEME zur Spracherkennung finden eine zunehmende Verbreitung und Beliebtheit im alltäglichen Leben. Das Spektrum dieser Anwendungen ist dabei Vielfältig und reicht vom Diktieren von Nachrichten über das Steuern von Geräten bis hin zum Einsatz in Autos. Dabei ist die Qualität der Spracherkennung und die Reaktion des Systems ein entscheidender Faktor, um die Interaktion so natürlich wie möglich zu gestalten [1]. Allerdings ergibt sich hier ein Hindernis für mehrsprachige Nutzer. Die natürliche Interaktion wird limitiert, da automatische Spracherkennungssysteme den Anwender auf eine voreingestellte Sprache beschränken. In den meisten herkömmlichen Systemen werden Sprachen sowie Dialekte unabhängig voneinander betrachtet. Es wird für jede Sprache ein separates akustisches Modell trainiert [2]. Bei weltweit etwa 7000 gesprochenen Sprachen ist es daher nur konsequent, multilinguale Spracherkennungssysteme zu entwickeln [3]. Allerdings erfordert ein solches System einen entsprechenden Satz an markierten Trainingsdaten, um wiederkehrende Muster der Sprache zu erkennen. Dieser

Umstand sorgt für erhebliche Qualitätsunterschiede zwischen den Sprachen, da nicht alle Sprachen über solche Datensätze verfügen. Um die Knappheit der beschrifteten Trainingsdaten zu kompensieren, wird der Ansatz der geteilten Hidden Layer genutzt [4]. Dieser Ansatz stützt sich auf das Zusammenführen aller Daten, um so eine gemeinsame Nutzung der Phoneme zu gewährleisten. Phoneme stellen dabei eine abstrakte Repräsentation aller Laute einer Sprache dar [5]. Um akustische Modelle für eine Vielzahl von Sprachen zu trainieren, um die Kosten, die beim Training dieser Modelle entstehen zu reduzieren und um neue Anwendungsszenarien zu unterstützen, besteht ein wachsendes Interesse an der Entwicklung mehrsprachiger Spracherkennungssysteme [1].

Zu Beginn erfolgt die Erläuterung des grundlegenden Aufbaus eines solchen Systems. Dabei werden die Unterschiede zu einem monolingualen System hervorgehoben. Darauf aufbauend wird erläutert, wie die Identifikation sowie die Erkennung von Sprachen funktioniert. Anschließend werden die Recurrent Neural Networks sowie deren Erweiterung, die Long Short Term Memory-Netzwerke (LSTM) beschrieben, welche heute im Bereich der multilingualen Spracherkennung verwendet werden. Dabei wird beleuchtet, wie dieses funktioniert und welche Vorteile gegenüber anderen tiefen neuronalen Netzen bestehen. Das Training eines solchen Modells folgt im Anschluss mit einer abschließenden Diskussion bezüglich weiterhin bestehender Probleme und zukünftiger Ansätze.

## II. VERWANDTE ARBEITEN

Dieses Kapitel stellt exemplarisch wichtige Arbeiten vor, welche mit dem Thema des Artikels in Beziehung stehen. Es gibt viele Forschungsarbeiten auf dem Gebiet der mehrsprachigen und sprachübergreifenden Spracherkennung. Der Artikel konzentriert sich allerdings nur auf diejenigen, die Recurrent Neural Networks bzw. LSTM-Netzwerke verwenden. Der Schwerpunkt dieser Arbeit liegt bei dem Untersuchen dieser Verfahren zur Realisierung entsprechender Systeme sowie die sich hier ergebenden Vorteile gegenüber bisheriger Verfahren. Dabei wird kein detaillierter Vergleich verschiedener Modelle aufgeführt.

Die Abhandlung lehnt an das Werk Automatic Speech Recognition - A Deep Learning Approach von Dong Yu und

Li Deng [1] an. Die Grundlagen bezüglich automatischer Spracherkennungssysteme, konventioneller Ansätze und Trainingsverfahren sowie die Architektur mehrsprachiger Systeme werden hier beschrieben. Ein weiteres für diesen Artikel interessantes Werk ist das Buch Sprachverarbeitung von Beat Pfister und Tobias Kaufmann, in welchem Grundlagen und Methoden der Sprachsynthese und Spracherkennung genau beschrieben werden. Des Weiteren wird in [6] von Tian et al. ein alternatives LSTM-Netzwerk vorgeschlagen, welches den konventionellen Ansatz übertrifft. Auch in den Arbeiten von Graves et al. [7] und Sak et al. [8] werden Recurrent Neural Networks im Bezug auf Spracherkennung untersucht. Dabei wird ebenfalls die Effizienz von LSTM-Netzwerken unter anderem durch Experimente bestätigt.

Da vor allem Sprachen mit einem geringen Satz an Trainingsdaten zu Problemen bei Spracherkennungssystemen führen, ist das Multitask Learning (MTL) ein wichtiger Ansatz multilingualer Sprachsysteme. In der Arbeit von Lu et al. [9] werden daher verschiedene Methoden des MTL vorgeschlagen. In dem Artikel wird belegt, dass das Verfahren den Mangel an Ressourcen kompensieren kann, indem auf gemeinsam erlernte Inhalte zurückgegriffen wird.

### III. HINTERGRUND

Ein multilinguales Spracherkennungssystem besteht aus mehreren Komponenten. Abbildung 1 illustriert dabei die Pipeline dieser Module. Die Erkennung der Sprache funktioniert über das Aufnehmen von Schallwellen, die beim Sprechen produziert werden. Diese lassen sich über einen elektroakustischen Wandler (Mikrophon) in ein elektrisches Signal umwandeln. Das elektrische Tonsignal wird daraufhin digitalisiert bzw. in Bits konvertiert (Sampling) und über Vorverarbeitung entsprechend aufbereitet, um es in ein neuronales Netz zu speisen [10]. Diese Daten lassen sich anschließend in Sequenzen aufteilen, aus denen die benötigten Features extrahiert werden. Abbildung 1 stellt diesen Teilschritt als Spektrogramm dar, welches das gesamte Frequenzspektrum visualisiert. Die Feature-Vektoren müssen hier so gewählt werden, dass die kleinste, effizienteste Menge für die Sprachverarbeitung herausgefiltert wird. Die gewonnenen Features dienen schließlich als Eingabe für die Sprachidentifikation. Die gewonnene Information bezüglich der gesprochenen Sprache kombiniert mit den Features werden als Eingabe für den Decoder genutzt. Unter Zuhilfenahme des akustischen Modells sowie des Sprach- und Lexikalmodells, wird der gesprochene Text analysiert und klassifiziert. Die drei Modelle werden von Bäckström [11] wie folgt beschrieben:

- *Akustikmodell.* Die Menge an Daten, die das neuronale Netz darüber informiert wie die Zusammenhänge zwischen Phonemen und einem konkreten Audiosignal sind. Die Phoneme können sowohl kontextabhängig als auch kontextfrei sein. Erlernt wird das Modell durch Audioaufnahmen und den zugehörigen Abschriften – die akustischen Trainingsdaten.
- *Lexikalmodell.* Dieses Modell bildet eine Sequenz von Phonemen, die durch das Akustikmodell gewonnenen

werden, auf gültige Wörter einer Sprache ab. Hierfür werden textuelle Trainingsdaten eingesetzt.

- *Sprachmodell.* Die Wahrscheinlichkeit für einen syntaktisch und semantisch korrekten Satz wird genutzt, um aus einer Reihe von Wörtern, die durch das Lexikalmodell gewonnen werden, gültige Wortsequenzen bzw. Sätze zu bilden. Beispielsweise folgt auf das englische Wort 'thank' mit einer hohen Wahrscheinlichkeit das Wort 'you' oder 'god'. Für das Training dieses Modells werden textuelle Trainingsdaten eingesetzt.

Jedes dieser drei Modelle muss separat trainiert werden. Das führt zu einer erhöhten Komplexität, verglichen mit dem Trainieren eines einzelnen, gemeinsamen Modells. Darum wird in den letzten Jahren vermehrt der Ansatz verfolgt, Ende-zu-Ende-Systeme zu entwickeln. Dabei werden die drei Modelle als ein System trainiert und eingesetzt. Chan et al. [12] und Prabhavalkar et al. [13] zeigen hierzu verbesserte Ergebnisse, verglichen mit mehreren Systemen welche auf einzelne Modelle bauen.

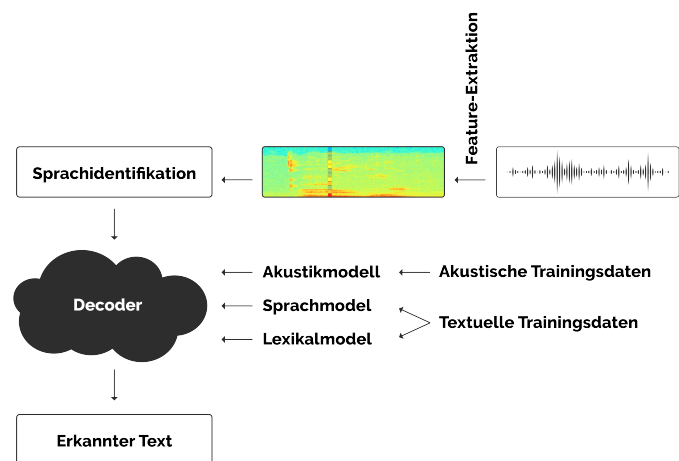


Abbildung 1. Pipeline eines Spracherkennungssystems (Eigene Darstellung, in Anlehnung an: [11])

### IV. SPRACHIDENTIFIKATION

Systeme zur Sprachidentifikation werden eingesetzt, um die Sprache eines Audiosignals zu klassifizieren. Um genauere Vorhersagen zu treffen, ist dies der erste Schritt in multilingualen Spracherkennungssystemen. Erst mit der Identifikation können eingehende Laute entsprechend zugeordnet werden. Ausdrücke und Grammatikregeln lassen sich somit ableiten und erhöhen die Erkennungsgenauigkeit der Systeme [14]. Die Einsatzgebiete lassen sich laut Zissman et al. [5] in zwei Kategorien einteilen. Dazu zählen die Vorverarbeitung für maschinelle Systeme und die Vorverarbeitung für menschliche Zuhörer. Unter ersterem wird ein sprachgesteuertes System verstanden, welches beim Einsprechen des Texts die Identifikation durchführt, um anschließend mithilfe des korrekten Sprachmodells die gesprochene Sprache zu erkennen. Eine Vorverarbeitung für menschliche Zuhörer geht gleich vor. Der Unterschied liegt darin, dass die weitere Verarbeitung nicht

von der Maschine vorgenommen wird, sondern durch einen Menschen.

Eine Sprache lässt sich anhand gewisser Unterschiede identifizieren. Zissman et al. [5] nennen als Unterschiede folgende Charakteristika:

- *Phonologie.* Hier wird die Häufigkeit und Verteilung von Phonemen und Phonem betrachtet. Ein Phonem ist der tatsächlich produzierte Ton, der beim Sprechen entsteht. Phoneme sind als kleinste, bedeutungsunterscheidende Einheiten der Lautsprache definiert. Phoneme werden zur Repräsentation der Aussprache genutzt.
- *Morphologie.* Sprachen unterscheiden sich in den Wortstämmen, dem Vokabular und der Art, wie Wörter geformt werden.
- *Syntax.* Sätze haben in unterschiedlichen Sprachen, unterschiedliche Satzstrukturen.
- *Prosodie.* Tempo, Rhythmus, Pausen und Tonhöhen unterscheiden sich von Sprache zu Sprache.

#### A. Architektur

Die Umsetzung der Sprachidentifikation spiegelt sich in der gewählten Architektur eines automatischen Spracherkennungssystems wieder. Gonzalez-Dominguez et al. [2] unterscheiden hierbei zwischen drei möglichen Umsetzungen.

Eine Möglichkeit eine Sprache zu identifizieren, ist der Einsatz eines dedizierten Systems. In Abbildung 1 ist dieser Architekturansatz dargestellt. Hierbei wird anhand eines Teilstückes des Eingangssignals die Sprache bestimmt. Niesler et al. [15] geben für dieses Teilstück eine durchschnittliche Dauer von 2,3 Sekunden an, bestätigt jedoch auch, dass mit zunehmender Länge die Genauigkeit steigt. Für die konkrete Implementierung eines dedizierten Systems zur Sprachidentifikation gibt es mehrere Ansätze [15]. Neben dem Einsatz eines Gaussian Mixture Models (GMM) kann hierfür auch ein neuronales Netz eingesetzt werden. Ein Nachteil der Spracherkennung anhand eines Teilstückes ist die erhöhte Latenz. Diese kann abhängig von der zu erzielenden Genauigkeit unterschiedlich lang sein. Sollte die Sprache in diesem Schritt falsch erkannt worden sein, breitet sich der Fehler weiter aus und führt zu einem falschen Resultat.

Eine weitere Möglichkeit setzt auf mehrere monolinguale Spracherkennungssysteme [2]. Das Eingangssignal wird simultan von mehreren Systemen mit jeweils eigenen Modellen verarbeitet. Anhand der größten Übereinstimmung mit einer Sprache wird am Ende die passende Sprache ausgewählt. Das löst die Probleme des vorherigen Ansatzes. Nachteilig ist der erhöhte Rechenaufwand durch den Einsatz mehrerer Systeme. Die Umsetzung, auf die sich diese Arbeit konzentriert, geht vom Trainieren eines universellen Modells aus. Dies wird erreicht, indem alle Sprachen als Eingabe infrage kommen. Die Hidden Layer eines neuronalen Netzes teilen sich die Repräsentationen der Phoneme. In den Ausgabeschichten wird die Sprache erkannt [1]. Vorteile ergeben sich durch die gemeinsame Nutzung von Phonemen, wie im nächsten Kapitel gezeigt wird. Soll eine neue Sprache antrainiert werden, so kann auf bereits vorhandenen Strukturen zurückgegriffen

bzw. aufgebaut werden. Das System erreicht somit nicht die Komplexität mehrerer monolingualer Systeme [14].

#### V. MULTILINGUALE SPRACHERKENNUNG

Die Kernidee der mehrsprachigen Spracherkennung ist bei den verschiedenen Architekturen dieselbe. Die Hidden Layer des Deep Neural Networks können als intelligentes Merkmalsextraktionsmodul betrachtet werden, welches aus mehreren Quellsprachen trainiert wird. Nur die Ausgabeschicht liefert eine direkte Übereinstimmung mit den relevanten Klassen. So lassen sich die Extraktoren für eine Reihe verschiedener Sprachen gemeinsam nutzen. Wie im folgenden Kapitel erläutert wird, lässt sich somit besonders das Problem beim Lernen der tiefen neuronalen Netze kompensieren. Diese lassen sich aufgrund ihrer Parameter und dem sogenannten Backpropagation-Algorithmus langsamer trainieren. Ein weiterer Vorteil, den dieser Ansatz bietet ist, dass auch mit Sprachen, die nur einen geringen Satz an markierten Trainingsdaten bieten, erlernt werden können. Indem Elemente anderer Sprachen gemeinsam genutzt und übertragen werden, lässt sich diese Herausforderung lösen. Merkmale, die aus diesen neuronalen Netzen extrahiert werden, lassen sich kombinieren, um so die Erkennungsgenauigkeit zu verbessern [1].

Eine gemeinsame Nutzung dieser Elemente wird ermöglicht, indem Phoneme zwischen den Sprachen genutzt werden. Da es zwischen verschiedenen Sprachen gleiche Phoneme gibt, müssen diese nicht neu erlernt werden. Um die genannten Ansätze der Sprachidentifikation sowie die der Spracherkennung zu nutzen, müssen Beziehungen zwischen den akustischen Signalen der Sprachen erkannt werden. Jede Sprache besitzt dabei ihre eigenen Charakteristika, wie bereits hervorging.

In der Sprachübergreifenden Erkennung gibt es einen Satz aus trainierten sowie schlecht bzw. untrainierten Phonemen, die erkannt werden müssen. Die Töne einer Sprache werden mit einem ähnlichen bzw. dem ähnlichsten trainierten Ton einer anderen Sprache ersetzt. Unbekannte Wörter lassen sich somit aus bekannten Phonemen zusammensetzen und korrekt vorhersagen [16].

Beim Transfer des Modells wird eine neue Softmax-Ebene angelegt und auf eine bestimmte Sprache trainiert, während das gesamte Netzwerk auf die neue Sprache abgestimmt wird. Die Softmax-Funktion wird hierbei lediglich zur Klassifikation verwendet und sorgt dafür, dass der Output immer in einem gleichen Bereich liegt [1]. Die Ausgabeknoten dieser Schicht entsprechen den Senonen der Zielsprache. Senonen beschreiben hier lediglich das Betrachten des lautlichen Kontextes der einzelnen Phoneme [1]. Diese Kontexte können komplex sein, da sie zusätzlich den linken und rechten Ton eines Phonems betrachten [17].

Ein entsprechende Architektur ist in Abbildung 2 illustriert. Sie zeigt die gemeinsam genutzten Schichten, die die Merkmale extrahieren sowie die unterschiedlichen Input-Datensätze der einzelnen Sprachen. Jede Sprache hat ihre eigene Softmax-Ebene. Wird ein neuer Datensatz in das System gegeben, werden nur die sprachspezifische Softmax-Ebene angefügt und

trainiert sowie die Hidden Layer angepasst. Andere Softmax-Ebenen bleiben unbeeinflusst [1]. Dies ist in Abbildung 2 zu sehen.

Dieser Ansatz bringt eine Verbesserung gegenüber monolingualen Netzwerken. Ein Vergleich eines monolingualen Deep Neural Networks und eines multilingualen Deep Neural Networks ist in Tabelle I aufgeführt. Das monolinguale Netzwerk wurde hierbei nur mit jeweils einer der Sprachen französisch, deutsch, spanisch und italienisch trainiert, während das multilinguale System mit allen vier Sprachen trainiert wurde. Dabei wird die prozentuale Wortfehlerrate (Word error rate, WER) angegeben. Es ist zu erkennen, dass das multilinguale System das monolinguale in allen Sprachen übertrifft. Diese Verbesserung ist dem sprachübergreifenden Wissen zuzuschreiben [1]. Die Steigerungen sind zusätzlich relativ in Prozent angegeben.

In [19] wurden eine Reihe weiterer Versuche durchgeführt, um die Wirksamkeit eines solchen Systems zu evaluieren. Dabei werden zwei verschiedene Zielsprachen verwendet. Zum einen das amerikanische Englisch, welches phonetisch nahe an den europäischen Sprachen der oben aufgeführten Tabelle liegt und Mandarin-Chinesisch, welches kaum Gemeinsamkeiten zu europäischen Sprachen bietet. Beim Vorhersagen des Gesprochenen kommt die Sprachidentifikation ins Spiel, durch welche Wörter ausgeschlossen werden können, die ebenfalls in Frage kommen, allerdings zum Wortschatz einer anderen Sprache gehören. Es wird hier mit statistischen Modellen gearbeitet, um anzugeben, mit welcher Wahrscheinlichkeit welches Wort vorkommt oder auf ein vorhergehendes folgen könnte. Dabei gibt es verschiedene Lösungsansätze, um das Gesprochene vorherzusagen. Hier wurden bisher tiefe neuronale Netze in Verbindung mit Hidden Markov-Modellen eingesetzt. Diese hybriden Systeme werden in der Literatur untersucht und beschrieben. Ein allerdings leistungsfähigeres Modell bieten die Recurrent Neural Networks. Diese Form von neuronalen Netzen werden heutzutage eingesetzt und erreichen hohe Genauigkeiten [1].

## VI. RECURRENT NEURAL NETWORKS

Spracherkennungssysteme erreichen ihre Erkennungsgenauigkeit durch den Einsatz von Recurrent Neural Networks. Das Modell dieser Netze erlaubt gerichtete, zyklische Verbindungen zwischen den Neuronen, wodurch es mit einem temporalen Verhalten ausgestattet wird. Recurrent Networks sind somit zum Lernen von Datensequenzen geeignet. Sprachen (kontinuierliche Audiostreams) fallen somit ebenfalls in das Anwendungsgebiet. Diese Form von neuronalen Netzen unterscheiden sich grundlegend von einem Feed Forward Deep Neural Network, da es nicht nur basierend auf Eingaben arbeitet, sondern auch auf interne Zustände zurückgreift. Die internen Zustände speichern die vergangenen Informationen in der zeitlichen Reihenfolge, in welcher diese verarbeitet wurden. Somit ist ein Recurrent Neural Network dynamischer, als ein Deep Neural Network, welches lediglich eine statische Eingabe-Ausgabe-Transformation durchführt [1]. In Abbildung 3 ist ein vereinfachtes Modell illustriert.




Abbildung 3. Modell des Recurrent Neural Network [18]

Die Abbildung zeigt links ein Netzwerk A, welches über eine Rückkopplung verfügt. Dieses Netzwerk bekommt einen Input  $x$  und gibt einen Output bzw. Zustand  $E$  zurück. So kann die Information von einem Schritt zum nächsten gelangen. Das ausgerollte Netzwerk wird rechts daneben dargestellt. Es zeigt eine Folge von Iterationen.  $s$  bezeichnet den jeweiligen Schritt und  $E$  den entsprechenden Hidden State, welcher sich beim Eingeben von Daten zum Zeitpunkt  $s$  ergibt. Ein Recurrent Neural Network gibt somit nicht nur den Input an die nächste Iteration, sondern zusätzlich den daraus resultierenden Zustand. Vorhergehende Schritte beeinflussen so die darauf folgenden [1].

Dies führt allerdings zu einem Problem. Dadurch, dass die Zustände immer weiter angepasst werden, verschwindet bzw. verschwimmt im Laufe der Zeit Information. Dies ist als Vanishing Gradient Problem bekannt und ergibt sich dadurch, dass Recurrent Neural Networks nicht in der Lage sind, auf Informationen zurückzugreifen, die weit in der Vergangenheit liegen. Der Kontext kann demnach bereits vergessen worden sein. Dieses Phänomen wird an Abbildung 4 deutlich. Das einmalige Anwenden der Sigmoidfunktion sorgt dafür, dass ein beliebiger Eingabewert zwischen  $-1$  und  $1$  liegt. Wendet man die Funktion mehrmals an, flacht die Kurve ab und es kann keine Änderung mehr erkannt werden. Die Ausgaben streben alle den gleichen Wert an [20].

So kann eine inkorrekte Vorhersage stattfinden. Aufgrund dessen wurden Long Short Term Memory-Netzwerke entwickelt, die zur Lösung des Problems beitragen. Dabei werden Recurrent Neural Networks mit einer Speicherstruktur erweitert, was zur Namensgebung führt. Diese Netzwerke sind in der Lage, anhand des Kontextes zukünftige Wörter vorherzusagen und so ihre Genauigkeit zu erhöhen. Auch beim Lernen und Erkennen verrauschter, geräuschverzerter oder hallender Aufnahmen bzw. schlechten Bedingungen beim Bearbeiten der Merkmale kann diese Form von Netzwerken bessere Ergebnisse erzielen [1]. Die verbesserte Genauigkeit gegenüber gewöhnlichen tiefen neuronalen Netzen wird in verschiedenen Arbeiten belegt [1], [21].

Diese Form von Netzwerken erlauben die Erkennung von Mustern und Zusammenhängen zeitlich getrennter Ereignisse. Somit eignen sie sich um Zeitreihen zu verarbeiten und vorherzusagen. Sogar, wenn zwischen wichtigen Ereignissen Verzögerungen liegen, die eine unbekannte Länge aufweisen. Die grundsätzliche Idee dabei ist es über elementweise Mul-

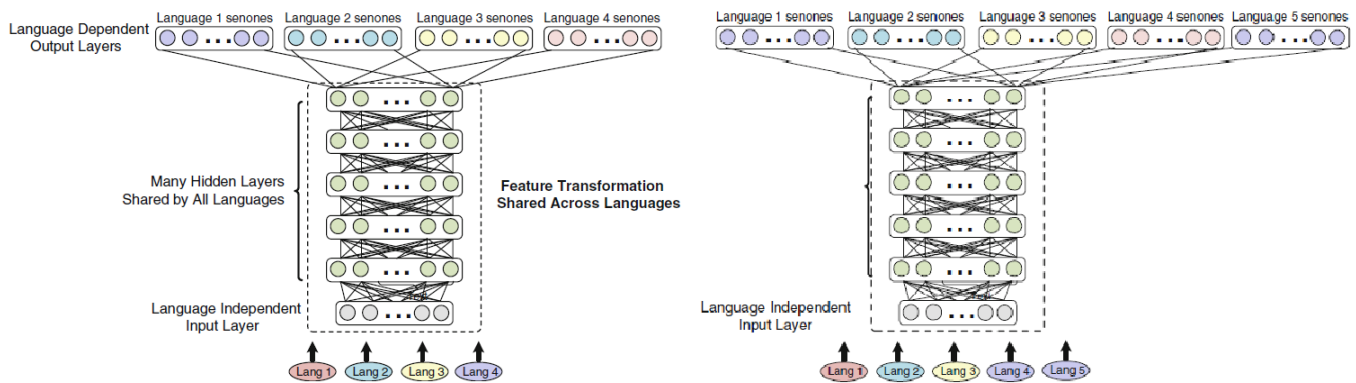


Abbildung 2. Hinzufügen einer neuen Sprache [18]

	FRA	DEU	ESP	ITA
Test set size (words)	40k	37k	18k	31k
Monolingual DNN WER	28.1%	24.0%	30.6%	24.3%
Multilingual DNN WER	27.1% (-3.6%)	22.7 (-5.4%)	29.4 (-3.9%)	23.5% (-3.3%)

Tabelle 1

RELATIVE WORTFEHLERRATE [1]




Abbildung 4. Vanishing Gradient Problem verdeutlicht an der Sigmoidfunktion [20]

tiplikationen den Informationsfluss in dem Netzwerk zu steuern. Eine LSTM-Zelle kann als intelligente Netzwerkeinheit betrachtet werden, welche Informationen über einen Zeitraum speichern kann. Dies wird durch eine Gating-Struktur erreicht. Die Information passiert verschiedene Gatter. Es wird bestimmt, wann es wichtig ist, sich an vorhergehende Eingaben zu erinnern, wann sich die Zelle Informationen weiter merken oder diese vergessen sollte und wann sie die Information ausgibt. Ein Gatter ist dabei nichts weiter, als eine Reihe von Multiplikationen bzw. Matrixoperationen [1]. Das System ist somit in der Lage aus dem Kontext heraus genaue Vorhersagen zu treffen, wodurch die Spracherkennung präziser wird. Eine Darstellung einer LSTM-Zelle ist Abbildung 5 zu sehen. Der Input  $x$  wird zur Zeit  $t$  von mehreren Quellen in die Zelle eingespeist. Dabei wird  $x$  an alle Gatter übergeben. Die Gatter

i (Input), f (Forget), c (Memory cell), o (Output) und h (Hidden vector bzw. der resultierende Zustand) haben dabei ihre eigene Gewichtungsfunktion [7].




Abbildung 5. Modell einer LSTM-Zelle [20]

Allerdings ist es selbst heute nicht möglich das Spracherkennungsproblem allgemein zu lösen. Spracherkennungssysteme werden somit nur für bestimmte Anwendungsfälle oder Szenarien konzipiert. Mit einer solchen Spezialisierung auf entsprechende Anwendungsgebiete können höhere Genauigkeiten erreicht werden. Zudem wird nicht so viel Rechenleistung und Speicher benötigt [10]. Vor allem bei der multilingualen Spracherkennung besteht die Schwierigkeit Gemeinsamkeiten verschiedener Sprachen zu nutzen, um Sprachen mit wenig Trainingsdaten mit einer ausreichenden Genauigkeit anzubieten. Es gilt die Sprachen zu finden, die zur besten Erkennungsleistung der neuen Sprache führen. Dabei müssen Beziehungen zwischen den Sprachen erkannt werden.



Problematisch ist auch, dass gleiche Phoneme je nach Sprecher und Sprache variieren, was dazu führt, dass Phoneme nur im Kontext betrachtet werden (sogenannte Triphon-Zustände) [1]. Spracherkennungen verschiedener Unternehmen erreicht heute niedrige Wortfehlerraten (Google liegt bei 4,9%), was auf die Menge von Trainingsmaterial zurückzuführen ist [22] [23] [24]. In der Literatur wird außerdem gezeigt, dass verschiedene Kombinationen von tiefen neuronalen Netzen und LSTM-Netzwerken zu einer weiteren Verbesserung führen [7].

## VII. TRAININGSVORGANG

Der Trainingsvorgang basiert auf dem bereits vorgestellten neuronalen Netz. Dieses besteht aus folgenden Schichten:

- Input-Schicht
- Hidden-Schicht
- Output-Schicht

Bei den Eingangsdaten der Input-Schicht handelt es sich um beschriftete Sprachaufnahmen, die in die Netztopologie eingespeist werden. Eine Vorklassifizierung der Sprache führt zu einer erhöhten Spracherkennungsrate. Dies ging bereits aus [25] hervor. Das Training des Modells geschieht in den Hidden Layer. Hier gilt es die Neuronen bzw. deren Gewichtungen entsprechend anzupassen. Im Kontext der Spracherkennung bedeutet dies, dass die Phoneme einer Sprachen extrahiert und erlernt werden müssen. Dabei wird die Sigmoidfunktion als Aktivitätsfunktion eingesetzt (s. Formel 1). Diese Funktion beschreibt die Korrelation zwischen Input-Wert und Aktivitätslevel eines Neurons. Der Input-Wert wird auf der X-Achse aufgetragen, das zugehörige Aktivitätslevel auf die Y-Achse. Der Aktivitätslevel wird durch eine Ausgabefunktion in den Output transformiert, den das Neuron an andere Neuronen weitersendet [26]. Das Netz wird beginnend von der Input-Schicht bis zur Output-Schicht vollständig durchlaufen.

$$\text{sigm}(x) = \frac{1}{1 + e^{-x}} \quad (1)$$

Dabei wird eine Erweiterung des Backpropagation-Algorithmus eingesetzt. Die Backpropagation-Through-Time-Methode sorgt für das Berechnen der Gradienten. Diese werden im Gegensatz zum Standardalgorithmus über die einzelnen Zeitschritte aufsummiert. In dieser Erweiterung des Backpropagation, welche in Recurrent Neural Networks eingesetzt wird, werden lediglich die Parameter einzelner Zeitschritte zwischen den Ebenen geteilt. Dieses Verfahren wird benötigt, um fehlerhafte Kantengewichte herauszufinden, um diese anzupassen. Die Kantengewichte des Netzes werden mit Null initialisiert. Die Ableitung der Sigmoidfunktion wird bei der Korrekturberechnung notwendig (s. Formel 2). Bei größeren Datenmengen entsteht ein Nachteil, welcher sich auf die Wissensausprägung des Netzes auswirkt.

Beim umgekehrten Durchlaufen entsteht allerdings ein Wissensverlust [25]. Dieser Verlust wird durch das Maxima der Ableitung  $\text{sigm}(x)'$  repräsentiert. Dieser kann bis zu 25% betragen. Der entstehende Verlust würde die

Klassifizierungsrate des Trainingsmodells reduzieren, welches in Abbildung 6 dargestellt ist [27].

$$\text{sigm}(x)' = \frac{e^x}{(e^x + 1)^2} \quad (2)$$




Abbildung 6. Darstellung der Sigmoidfunktion und dessen Ableitung [27]

Anstelle der Sigmoidfunktion wird in den heutigen Netzen jedoch die sogenannte Rectified Linear Units-Funktion (*ReLU*s) verwendet (s. Formel 3). Diese Funktion ist dem menschlichen Neuron am ähnlichsten und bringt zudem eine erhöhte Verarbeitungsgeschwindigkeit mit sich [28]. Die Berechnung der Kantengewichte erfolgt durch Formel 4.

$$y_j = \text{ReLU}(x_j) = \max(0, x_j) \quad (3)$$

$$x_j = b_j + \sum x_{ij} * y_j \quad (4)$$

Die Output-Schicht ordnet schließlich die Eingangsdaten den Klassen (Zielsprachen) zu. Diese Schicht ist als Softmax-Schicht konfiguriert, wie bereits aus dem letzten Kapitel hervorging. Die Klassen werden hier in einer eindimensionalen Matrix kategorisiert. Dabei ist die Matrix in dem Zahlenintervall  $[0, 1]$  normalisiert. Die endgültige Sprachidentifikation geschieht über diese normalisierten Werte. Abbildung 7 stellt dies dar. Die Werte lassen sich in Wahrscheinlichkeiten ausdrücken, indem sie mit dem Faktor 100 multipliziert werden [27]. Die Vorhersagen der Output-Schicht geschieht durch die



Abbildung 7. Klassenzuordnung über Wahrscheinlichkeiten in der Softmax-Konfiguration [27]

Funktion  $p(j)$  (s. Formel 5). Dabei steht der Index 1 für die jeweilige Sprache.

$$p(j) = \frac{\exp(x_j)}{\sum_l \exp(x_l)} \quad (5)$$

Für das erwähnte Backpropagation-Verfahren wird ebenfalls eine Kostenfunktion benötigt. Diese geschieht durch die Cross

Entropy Loss-Funktion. Diese Funktion misst die Abweichungen der Kantengewichte der Netztopologie und passt diese rückwirkend an. Der Cross Entropy-Verlust nimmt zu, wenn der vorhergesagte Wert von der tatsächlichen Beschriftung abweicht [29]. Bei  $t_j$  handelt es sich um die Klasse, für die der Verlust berechnet wird [18].

$$C = \sum_l t_j * \log(p_j) \quad (6)$$

#### A. Netztopologie

Die Netztopologie beschreibt die Infrastruktur des Netzes. Die Auswahl der Topologie bestimmt die Qualität des Trainingsvorgangs. Eine zu geringe Anzahl der Neuronen führt zu einer niedrigen Spracherkennungsrate. Eine zu hohe Anzahl würde zu einer überhöhten Trainingsdauer führen. Die Topologien unterscheiden sich zwischen verschiedenen Ansätzen und liefern Spracherkennungsergebnisse [25].

In dieser Arbeit wird der Topologievorschlag von Gonzales et al. betrachtet. Für die Eingangsdaten werden 40 Filterbanken verwendet. In der Input-Schicht werden 26 Neuronen eingesetzt. Um unerwünschte Latenzzeiten zu vermeiden, wird ein asymmetrischer Kontext verwendet. Die Hidden-Schicht besteht aus vier Ebenen mit einer Gesamtzahl von 2560 Neuronen. Die Output-Schicht enthält die Softmax-Konfiguration. Dies ist bei der Erkennung von multilingualen Sprachen eine erforderliche Konfiguration [18].

#### B. Verbesserung des Trainingsverfahrens durch Multitasking learning (MTL)

Bei maschinellem Lernen wird der Fokus auf das Optimieren bestimmter Metriken gesetzt. Dazu zählen beispielsweise die Klassifizierungsgenauigkeit und Trainingsdauer. Das Lernen der einzelnen Sprachen läuft sequenziell ab. Hier wird das Multitasking Learning eingesetzt. Dieser Ansatz zielt darauf ab, die Generalisierungsleistung einer Lernaufgabe zu verbessern. Dies wird erreicht, indem mehrere zusammenhängende Aufgaben gemeinsam gelernt werden und nicht sequenziell. Dies bedeutet jedoch nicht, dass die Aufgaben ähnlich sind. Sie müssen lediglich auf verschiedene Ebenen abstrahiert und geteilt werden. Dabei lässt sich das Wissen zwischen Aufgaben übertragen. Es wurde festgestellt, dass gemeinsames Lernen dafür sorgt, dass Wissen miteinander ausgetauscht wird und sich somit die Trainingsdauer verkürzt. Folglich hilft eine so gewonnene interne Repräsentation den Modellen, zukünftige Daten besser zu verallgemeinern. Beim gemeinsamen Nutzen der Phoneme findet dieser Ansatz somit Verwendung [9]. MTL ist auch nützlich, wenn die Menge der markierten Daten im Vergleich zur Modellgröße gering ausfällt. Das bedeutet, dass das geteilte Wissen der Ressourcenknappheit einiger Sprachen zugute kommt. Dieser Mangel an Sprachressourcen ist ein Hindernis automatischer Spracherkennungssysteme. Es werden grundsätzlich zwei Arten von MTL-Methoden unterschieden: Hard- und Soft Parameter Sharing.

Hard Parameter Sharing stellt die meist genutzte Art

dar [30]. Es wird auf die Hidden-Schicht angewendet, indem sich die Aufgaben gemeinsam lernen lassen, während die spezifischen Aufgaben separat erlernt werden. Dies wird in Abbildung 8 dargestellt. Der Ansatz reduziert das Overfitting-Risiko. Je mehr Aufgaben gleichzeitig erlernt werden, desto mehr muss das Modell eine Repräsentation finden, die sämtliche Aufgaben erfasst. Somit ist die Chance auf Overfitting geringer [30] [31].




Abbildung 8. Hard parameter sharing auf die Hidden-Schicht angewendet [27].

## VIII. DISKUSSION UND AUSBLICK

Die menschliche Sprache ist der natürlichste Weg etwas zu kommunizieren, so ist es nicht verwunderlich, dass das Interesse an Deep Learning-Ansätzen zur Spracherkennung und den damit verbundenen Anwendungen steigt. In dieser Arbeit wurde das Gegenstück zu den konventionellen, stochastischen Modellen beleuchtet - die Recurrent Neural Networks, mit der Erweiterung um die LSTM-Struktur. Dabei geht hervor, dass bei diesen Netzen die einzelnen Neuronen nicht isoliert betrachtet werden können. Vielmehr hängt deren Zustand und Aktivierung von den Aktivitäten anderer Neuronen bzw. Zellen ab. Vorhergehende Ereignissen beeinflussen den Zustand der folgenden. Durch die dynamische Rekursion und den Gattern wird ein Gedächtnis geschaffen, mit welchem sich die Netze an vergangene Zustände erinnern können und aufgrund dieser Erfahrungen genauere Vorhersagen treffen. Vor allem bei Datensequenzen ist dies hilfreich. Da die menschliche Sprache lediglich eine Sequenz von Tönen ist, eignet sich diese Form von Netzwerken ideal.

Multilinguale Spracherkennungssysteme haben mit verschiedenen Problemen zu kämpfen. Dazu zählt beispielsweise die Ressourcenknappheit einiger Sprachen, wodurch die Kernidee eines solchen Systems vom gemeinsamen Verwenden der Phoneme ausgeht. Um erlerntes Wissen gemeinsam zu nutzen, wird ein solches System über das Multitask Learning trainiert. Es geht hervor, dass mit der multilingualen Spracherkennung bessere Ergebnisse erzielt werden, als mit der monolingualen Erkennung. Dies ist auf das gemeinsame Nutzen der Phoneme zurückzuführen. Heutige Genauigkeiten beim Erkennen von Sprachen erreichen die Wortfehlerrate eines Menschen. Somit

ist das reine Verstehen bald nicht mehr das hauptsächliche Problem. Die Autoren sind der Meinung, dass eine natürliche Interaktion mit einem Spracherkennungssystem dennoch schwierig bleibt, solange das System keine Kenntnisse über seine Umwelt hat. Beispielsweise klingen im Deutschen die Worte 'Meer' und 'mehr' gleich, haben jedoch nichts gemeinsam. Diese Homophone lassen sich zwar verstehen, das Spracherkennungssystem erkennt allerdings nicht den Kontext und es könnte zu einer inkorrekten Vorhersage führen. Es bestehen auch weitere, zahlreiche limitierende Faktoren. Das Mapping von Wörtern und Sequenzen aus Phonemen braucht Linguistikexperten und stellt eine Herausforderung dar. Schließlich müssen sämtliche Phoneme der Sprache identifiziert werden. Auch der Stil beim Sprechen verändert sich ständig und ist nie gleich zwischen unterschiedlichen Sprechern. Gesprochene Wörter beeinflussen die Betonung der nächsten Worte. Die Zukunft im Bereich des maschinellen Lernens bleibt spannend. Wir sind überzeugt, dass in Zukunft fortschrittlichere Deep Learning-Architekturen für effektivere Spracherkennungssysteme entwickelt werden, die den hier diskutierten Netzwerken in vielerlei Hinsicht überlegen sind. Das Verständnis über die Struktur der Sprache, deren Dynamik und ihrer Repräsentation treiben den Forschungsfortschritt weiter voran. Ansätze, die in der Literatur zu finden sind, gehen davon aus, weitere Informationsquellen einzubeziehen, um die Qualität weiter zu verbessern. In diesem Zusammenhang wird in [1] das Nutzen visueller Daten erwähnt. Dabei werden Merkmale aus interessanten Gesichtsregionen extrahiert. Da visuelle Informationen unabhängig von akustischem Rauschen sind, soll hier eine Verbesserung erzielt werden. Offen bleibt die Frage, welche Ansätze in Zukunft entwickelt werden, um die Interaktion mit Spracherkennungssystemen zu einem natürlichen Prozess zu machen. Da Maschinen die Welt nicht verstehen wie wir, ist es schwierig aus Tönen den gesamten Kontext abzuleiten. Weitere Forschungen können hier anknüpfen und sich mit potentiellen Möglichkeiten zur Lösung dieses Problems auseinandersetzen.

#### LITERATUR

- [1] D. Yu and L. Deng, *Automatic Speech Recognition: A Deep Learning Approach*. Springer Publishing Company, Incorporated, 2014.
- [2] J. Gonzalez-Dominguez, D. Eustis, I. Lopez-Moreno, A. Senior, F. Beaufays, and P. J. Moreno, "A real-time end-to-end multilingual speech recognition architecture," *IEEE Journal of Selected Topics in Signal Processing*, vol. 9, no. 4, pp. 749–759, June 2015.
- [3] G. F. Simons and C. D. Fennig, Eds., *Ethnologue: Languages of the World, Twenty-first edition*. Dallas, Texas: SIL International. Online version, 2018. [Online]. Available: <http://www.ethnologue.com>
- [4] T. Schultz and A. H. Waibel, "Language independent and language adaptive large vocabulary speech recognition," in *ICSLP*, 1998.
- [5] M. A. Zissman and K. M. Berkling, "Automatic language identification," *Speech Commun.*, vol. 35, no. 1-2, pp. 115–124, Aug. 2001. [Online]. Available: [http://dx.doi.org/10.1016/S0167-6393\(00\)00099-6](http://dx.doi.org/10.1016/S0167-6393(00)00099-6)
- [6] X. Tian, J. Zhang, Z. Ma, Y. He, J. Wei, P. Wu, W. Situ, S. Li, and Y. Zhang, "Deep LSTM for Large Vocabulary Continuous Speech Recognition," *ArXiv e-prints*, Mar. 2017.
- [7] A. Graves, A. r. Mohamed, and G. Hinton, "Speech recognition with deep recurrent neural networks," in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing*, May 2013, pp. 6645–6649.
- [8] H. Sak, A. Senior, and F. Beaufays, "Long Short-Term Memory Based Recurrent Neural Network Architectures for Large Vocabulary Speech Recognition," *ArXiv e-prints*, Feb. 2014.
- [9] D. Chen and B. K. W. Mak, "Multitask learning of deep neural networks for low-resource speech recognition," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 23, no. 7, pp. 1172–1183, July 2015.
- [10] T. K. Beat Pfister, *Sprachverarbeitung - Grundlagen und Methoden der Sprachsynthese und Spracherkennung*. Springer, 2008.
- [11] T. Bäckström, "Speech recognition overview," 2016, (Accessed on 2018-06-25). [Online]. Available: [https://mycourses.aalto.fi/pluginfile.php/366508/mod\\_resource/content/1/slides\\_recognition\\_handout.pdf](https://mycourses.aalto.fi/pluginfile.php/366508/mod_resource/content/1/slides_recognition_handout.pdf)
- [12] W. Chan, N. Jaitly, Q. V. Le, and O. Vinyals, "Listen, attend and spell," *CoRR*, vol. abs/1508.01211, 2015. [Online]. Available: <http://arxiv.org/abs/1508.01211>
- [13] R. Prabhavalkar, K. Rao, T. Sainath, B. Li, L. Johnson, and N. Jaitly, "A comparison of sequence-to-sequence models for speech recognition," 2017. [Online]. Available: [http://www.isca-speech.org/archive/Interspeech\\_2017/pdfs/0233.PDF](http://www.isca-speech.org/archive/Interspeech_2017/pdfs/0233.PDF)
- [14] C. Bartz, T. Herold, H. Yang, and C. Meinel, "Language identification using deep convolutional recurrent neural networks," *CoRR*, vol. abs/1708.04811, 2017. [Online]. Available: <http://arxiv.org/abs/1708.04811>
- [15] T. Niesler and D. Willett, "Language identification and multilingual speech recognition using discriminatively trained acoustic models," 2006.
- [16] U. Uebler, "Multilingual speech recognition in seven languages," *Speech Communication*, vol. 35, no. 1, pp. 53 – 69, 2001, mIST. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S0167639300000959>
- [17] CMUSphinx, "Basic concepts of speech recognition," (Accessed on 2018-06-25).
- [18] J. Gonzalez-Dominguez, D. Eustis, I. Lopez-Moreno, A. Senior, F. Beaufays, and P. J. Moreno, "A real-time end-to-end multilingual speech recognition architecture," *IEEE Journal of Selected Topics in Signal Processing*, vol. 9, no. 4, pp. 749–759, 2015.
- [19] J. T. Huang, J. Li, D. Yu, L. Deng, and Y. Gong, "Cross-language knowledge transfer using multilingual deep neural network with shared hidden layers," in *2013 IEEE International Conference on Acoustics, Speech and Signal Processing*, May 2013, pp. 7304–7308.
- [20] DL4J, "A beginner's guide to recurrent networks and lstms," 2017, (Accessed on 2018-06-25).
- [21] H. Sak, A. Senior, K. Rao, and F. Beaufays, "Fast and Accurate Recurrent Neural Network Acoustic Models for Speech Recognition," *ArXiv e-prints*, Jul. 2015.
- [22] E. Protalinski, "Google's speech recognition technology now has a 4.9error rate," 2017, (Accessed on 2018-06-25).
- [23] A. Li, "Google's speech recognition is now almost as accurate as humans," 2017, (Accessed on 2018-06-25).
- [24] R. Price, "Microsoft's ai is getting crazily good at speech recognition," 2017, (Accessed on 2018-06-25).
- [25] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [26] neuronalesnetz, "Neuronale netze - eine einführung - aktivität," 2018, (Accessed on 2018-06-25).
- [27] GitHub, "Kulbear/deep-learning-nano-foundation," 2017, (Accessed on 2018-06-25). [Online]. Available: <https://github.com/Kulbear/deep-learning-nano-foundation/wiki/ReLU-and-Softmax-Activation-Functions>
- [28] M. Zeiler, M. Ranzato, R. Monga, M. Mao, K. Yang, Q. Le, P. Nguyen, A. Senior, V. Vanhoucke, J. Dean, and G. Hinton, "On rectified linear units for speech processing," in *38th International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, Vancouver, 2013.
- [29] M. Cheatsheet, "Loss functions — ml cheatsheet documentation," 2017, (Accessed on 2018-06-25). [Online]. Available: [http://ml-cheatsheet.readthedocs.io/en/latest/loss\\_functions.html](http://ml-cheatsheet.readthedocs.io/en/latest/loss_functions.html)
- [30] S. Ruder, "An overview of multi-task learning in deep neural networks," 2017, (Accessed on 2018-06-25). [Online]. Available: <http://ruder.io/multi-task/>
- [31] Y. Lu, F. Lu, S. Sehgal, S. Gupta, J. Du, C. H. Tham, P. Green, and V. Wan, "Multitask learning in connectionist speech recognition," 2015.